

# Projektbericht: Klassifikation von Gesichtern nach ethnischem Hintergrund mit Convolutional Neural Networks (CNN)

## 1. Beschreibung des Datensatzes

Für dieses Projekt wurde der UTKFace-Datensatz verwendet, der mehr als 10.000 Gesichtsbilder mit Labels wie Alter, Geschlecht und ethnische Zugehörigkeit umfasst.

Die Bilder haben standardisierte Abmessungen und zeigen Gesichter in verschiedenen Altersgruppen, Geschlechtern und ethnischen Gruppen, was eine Vielzahl von Gesichtstypen repräsentiert.

- **Balance des Datensatzes:** Der Datensatz ist teilweise unausgeglich, da einige ethnische Gruppen (z.B. „Weiße“) häufiger vertreten sind als andere. Diese Ungleichverteilung kann zu Herausforderungen bei der Generalisierung des Modells führen. Um die Auswirkungen dieses Ungleichgewichts zu verringern, wurden Techniken zur Datenaugmentation angewendet.
- **Bildquelle:** Die Bilder wurden aus öffentlich zugänglichen Quellen zusammengestellt und zeigen Personen unter verschiedenen Beleuchtungssituationen, Gesichtsausdrücken und Blickwinkeln, was zur Robustheit des Modells beiträgt. Die Standardisierung der Bildgröße erleichtert zudem die Verarbeitung im CNN.

Der UTKFace-Datensatz ist gut geeignet für Gesichtsanalyseprojekte, da er vielfältige demografische Informationen umfasst und sich gut für die Klassifikation und das Training von Modellen zur Gesichtserkennung und -analyse eignet.

## 2. Relevanz des Projekts für reale Anwendungen

Die Klassifikation von Gesichtern nach Alter, Geschlecht und ethnischer Zugehörigkeit ist in vielen Bereichen der realen Welt nützlich:

- **Demografische Analysen:** Unternehmen und Forscher können demografische Informationen nutzen, um Konsumverhalten zu verstehen

oder Produkte gezielter zu vermarkten. Ein Modell zur automatisierten Klassifikation nach Altersgruppen und ethnischer Zugehörigkeit könnte hier entscheidende Einblicke liefern.

- **Sicherheits- und Überwachungssysteme:** Die Klassifikation und Analyse von Gesichtern wird zunehmend in der Zugangskontrolle und Sicherheitsüberwachung eingesetzt. Durch eine zuverlässige Klassifikation könnten automatische Warnsysteme für bestimmte demografische Gruppen erstellt werden.
- **Personalisierung von Benutzererfahrungen:** Plattformen könnten Benutzeroberflächen und Inhalte dynamisch anpassen, um eine auf den Benutzer zugeschnittene Erfahrung zu bieten. Die Anpassung von Marketingstrategien oder Inhalten an Alters- und Geschlechtsgruppen könnte zu höheren Interaktionsraten führen.

Die Ergebnisse dieses Projekts schaffen eine Grundlage für weitere Entwicklungen in der automatisierten Gesichtsanalyse und können als erster Schritt für spezialisierte Gesichtserkennungsmodelle dienen.

### 3. Probleme und Lösungsansätze

Im Laufe des Projekts sind einige Herausforderungen aufgetreten:

- **Datenungleichgewicht:** Einige ethnische Gruppen waren im Datensatz stark unterrepräsentiert, was dazu führte, dass das Modell bestimmte Gruppen nicht gut generalisieren konnte. Um dies zu verbessern, wurden verschiedene Datenaugmentationsmethoden eingesetzt, die Bilder durch zufällige Transformationen wie Drehung, Spiegelung und Skalierung verändern.  
Diese Techniken erhöhen die Vielfalt der Trainingsdaten und verringern das Risiko von Überanpassung.

- **Überanpassung (Overfitting):** Während des Trainings zeigte sich, dass das Modell auf den Trainingsdaten sehr gute Ergebnisse erzielte, auf den Testdaten jedoch eine deutlich geringere Genauigkeit aufwies. Um dieses Problem zu reduzieren, wurden Dropout-Schichten in die Modellarchitektur eingefügt, die während des Trainings zufällig Neuronen deaktivieren und so die Generalisierung fördern. Zusätzlich wurde die Modellarchitektur vergrößert, indem mehr Convolutional- und Pooling-Schichten hinzugefügt wurden, was dem Modell mehr Kapazität für die Verarbeitung komplexer Merkmale gibt.
- **Schwierigkeiten bei der Konvergenz:** Die Konvergenz des Modells war aufgrund der Wahl der Lernrate und der Batchgröße anfangs instabil. Es wurden mehrere Werte getestet, um eine stabile Konvergenz zu erzielen. Schließlich stellte sich eine kleinere Lernrate in Kombination mit einer größeren Batchgröße als vorteilhaft heraus. Diese Kombination ermöglichte eine genauere Anpassung der Gewichte und führte zu stabileren Trainingsverläufen.

#### 4. Vorgehensweise und Begründung

Die Entwicklung des Projekts bestand aus mehreren sorgfältig geplanten Schritten, um eine hohe Genauigkeit und Generalisierbarkeit des Modells zu gewährleisten:

- **Datenvorbereitung und -augmentation:** Zu Beginn wurde der Datensatz vorbereitet und durch Augmentation erweitert. Methoden wie zufällige Helligkeitsanpassungen, Drehungen, Spiegelungen und Skalierungen wurden auf die Trainingsbilder angewandt, um das Modell robuster gegenüber Variationen der Gesichtsmerkmale zu machen. Durch diese Augmentationsmethoden wurde der ursprüngliche Datensatz effektiv vergrößert, und das Modell konnte eine größere Vielfalt von Gesichtsmustern erlernen.
- **Modellerstellung:** Es wurde ein Convolutional Neural Network (CNN) entwickelt, das durch mehrere Convolutional- und Pooling-Schichten die Merkmale der Bilder extrahiert. Die Modellarchitektur wurde iterativ

vergrößert, indem mehr Convolutional-Schichten mit einer höheren Anzahl von Filtern hinzugefügt wurden, um die Komplexität der Gesichtsbilder besser verarbeiten zu können. Dropout-Schichten wurden strategisch zwischen den Convolutional-Blöcken sowie vor der endgültigen vollvernetzten Schicht eingesetzt, um das Überanpassungsrisiko zu senken.

- **Hyperparameteroptimierung:** Im Rahmen der Hyperparameteroptimierung wurden verschiedene Kombinationen von Lernrate, Batchgröße und Anzahl der Epochen getestet. Eine Kombination aus einer kleineren Lernrate und einer erhöhten Anzahl von Epochen stellte sich als optimal heraus, um eine stabile und effektive Konvergenz zu erreichen. Auch ein Lernraten-Reduktionsplan wurde implementiert, der die Lernrate automatisch senkt, wenn sich die Leistung nicht verbessert. Dadurch konnte das Modell auch in späteren Epochen noch an Genauigkeit gewinnen.
- **Evaluierung und Anpassungen:** Während des Trainings wurde das Modell regelmäßig auf dem Testdatensatz evaluiert, um den Verlust und die Genauigkeit zu überwachen. Bei Bedarf wurden Anpassungen vorgenommen, wie z.B. die Erhöhung der Modellkomplexität oder die Einführung weiterer Dropout-Schichten. Ein vortrainiertes Modell (Transfer Learning) wurde ebenfalls in Betracht gezogen, um zu prüfen, ob dies die Genauigkeit des Modells steigern könnte, da vortrainierte Modelle oft eine bessere Ausgangsleistung bieten.

Durch diese Schritte konnte ein Modell entwickelt werden, das auf dem UTKFace-Datensatz eine solide Grundgenauigkeit für die Klassifikation nach ethnischer Zugehörigkeit,

Alter und Geschlecht erreicht. Weitere Anpassungen und die Implementierung eines vortrainierten Modells könnten die Genauigkeit des Modells noch weiter steigern und seine praktische Anwendbarkeit verbessern.